

Bears, Beets, Random Forests

Un approccio ibrido tra Apprendimento Supervisionato e Ontologie per
la classificazione semantica di *The Office*

Gruppo di lavoro:

Francesco Bernardi, mat. 758271, f.bernardi6@studenti.uniba.it

Link Repository

https://github.com/FraBernardi/progetto_icon_25_26_Bernardi.git

Anno Accademico 2025-26

Introduzione

Il dominio di interesse del progetto è la valutazione e la classificazione degli episodi della sitcom “The Office”, prodotta negli Stati Uniti e andata in onda dal 2005 al 2013 per un totale di 9 stagioni. La selezione del dominio è dovuta alla longevità dell’opera che consegue in una ricchezza sia di dati puramente statistici (voti del pubblico, numero di ascolti) sia di elementi narrativi. La serie presenta pattern ricorrenti e snodi fondamentali della trama, come i premi aziendali, le feste in ufficio e i matrimoni, che influenzano pesantemente la percezione di questa. Si dimostra, nel seguito, come l’integrazione della componente statistica e di quella semantica produca un modello di classificazione degli episodi nettamente più robusto e accurato

Sommario

Obiettivo del progetto è dimostrare come un sistema ibrido, capace di integrare apprendimento supervisionato e ragionamento automatico, sia un approccio più efficiente e affidabile rispetto ai meri dati statistici. Il sistema punta a estrarre il valore narrativo di un episodio a prescindere dal suo successo tra il pubblico. Il progetto si sviluppa in prima battuta addestrando modelli su dati statistici, per poi sviluppare un’ontologia in OWL e utilizzare un reasoner con lo scopo di dedurre la classificazione logica. Nella parte finale si mostra il reale impatto di questa nuova conoscenza integrata nel dataset iniziale.

Elenco argomenti di interesse

Il progetto analizza e integra in maniera pratica due macroaree affrontate nel Corso, dimostrando come una loro “fusione” generi un sistema classificatore superiore. In particolare, i moduli coinvolti sono:

- **Apprendimento supervisionato [Capitolo 7]** : addestramento di due modelli di classificazione (Decision Tree e Random Forest) tramite un dataset composto esclusivamente da metadati statistici (come voti o ascolti TV). I modelli vengono ottimizzati tramite GridSearchCV e valutati tramite metriche standard, quali Accuracy, Precision, Recall e F1-Score. I risultati costituiscono la baseline per dimostrare i limiti di un approccio puramente statistico.
- **Knowledge Graph, Ontologie e Ragionamento Automatico [Capitolo 6]** : superamento dei limiti statistici riscontrati nella prima fase. Applicazione dei concetti delle Logiche Descrittive per costruire una KB ontologica in linguaggio OWL, tramite l’editor “Protégé” per modellare gli elementi narrativi della sitcom. Utilizzo della libreria owlready2 e il motore di inferenza HermiT per il ragionamento automatico, volto alla classificazione semantica di ogni episodio (“Eccellente”, “Buono”, “Scarso”) basata esclusivamente sulle regole logiche scritte per il dominio
- **Unione operativa delle due sezioni precedenti**: integrazione della conoscenza semantica nel dataset originale come nuova feature ingegnerizzata. L’addestramento iterato su dati arricchiti dimostra in maniera pratica come l’approccio ibrido aumenti le performance del Random Forest.

Apprendimento Supervisionato

Sommario

Obiettivo di questo modulo è la determinazione di una baseline in termini di prestazioni, ovvero provare a predire il successo di un episodio di The Office basandosi solamente su metadati statistici e misurazione degli ascolti. A tale scopo, la variabile target continua originaria (rating IMDb) è stata trasformata in un problema di classificazione, tramite il raggruppamento degli episodi in tre categorie discrete: “Eccellente”, “Buono” e “Scarso”. I modelli vengono addestrati per tentare di dedurre queste classi dai soli numeri

Strumenti utilizzati

Lo sviluppo è stato effettuato in ambiente Python, sfruttando la libreria pandas per il partizionamento e la manipolazione del dataset, e la libreria **scikit-learn** per il Machine Learning. Sono stati selezionati e confrontati due modelli di classificazione: il Decision Tree Classifier (un albero singolo, facilmente interpretabile ma soggetto ad alta varianza) e il Random Forest Classifier (un modello ensemble che crea decine di alberi per fornire predizioni più robuste). Per scongiurare il problema dell'overfitting e selezionare i parametri ottimali, i modelli sono stati sottoposti a **GridSearchCV** all'interno di una Nested Cross-Validation.


Decisioni di Progetto

Il dataset originale contiene metadati di tutti gli episodi di The Office. La fase di preprocessing è stata fondamentale per garantire la corretta computazione da parte degli algoritmi. Si è deciso di escludere dal training set le feature puramente testuali e descrittive, come il titolo dell'episodio e la data di messa in onda, oltre che la trama letterale (“Title”, “Date”, “About”), in quanto dati non strutturati che non potevano essere processati dalla statistica pura. Le feature testuali categoriche (“Director”, “Writers”, “GuestStars”) sono state codificate in valori numerici attraverso lo strumento LabelEncoder. Una volta terminate le operazioni di pulizia, il dataset presentava solo variabili continue e categoriche numeriche


Valutazione

L'addestramento dei modelli sul dataset puramente statistico ha restituito le seguenti metriche di base (valutate su Accuracy, Precision, Recall e F1-Score):

- **Decision Tree Classifier:** ha raggiunto un'Accuracy media del **62.69%** (+/- 6.31%) e un F1-Score del **61.39%**. L'algoritmo ha individuato come iperparametri ottimali un criterio *Gini* con una max_depth di 6 e un min_samples_split di 5.
- **Random Forest Classifier:** grazie alla forza dell'approccio *ensemble*, l'Accuracy media è salita al **67.00%** (+/- 4.18%), con un F1-Score del **66.73%**. I parametri ottimali calcolati indicano la necessità di 50 alberi decisionali (n_estimators) per raggiungere questo risultato.



Come dimostrato dalla curva di apprendimento, il modello riesce ad apprendere dai dati, ma le performance complessive rimangono modeste. La spiegazione di questo limite statistico emerge chiaramente analizzando l'importanza assegnata dall'algoritmo alle singole variabili:



Sia il Decision Tree che la Random Forest hanno relegato al fondo della classifica elementi come gli sceneggiatori e i registi, assegnando un peso quasi esclusivo alla variabile Votes (il numero di voti ricevuti dall'episodio) seguita dalla Season (la stagione). Questo dimostra che il modello, privo di comprensione semantica, per predire se un episodio sia "Eccellente" usa la scorciatoia matematica della polarizzazione del pubblico: deduce che se un episodio ha un volume anomalo di voti, probabilmente si tratta di un finale di stagione o di un evento cruciale.

Tuttavia, questo approccio basato sui voti fallisce nel classificare correttamente la grande massa di episodi di qualità intermedia. I dati statistici da soli si sono rivelati insufficienti per valutare il reale impatto narrativo di *The Office*, evidenziando la necessità di introdurre nel dataset una reale conoscenza di dominio.

Rappresentazione della Conoscenza e Ragionamento Automatico

Sommario

Questo modulo affronta direttamente le limitazioni emerse nell'approccio puramente statistico della fase precedente. L'obiettivo è dotare il sistema di una reale "conoscenza di senso comune" e logico-narrativa applicata al dominio di *The Office*, permettendogli di valutare la qualità intrinseca della sceneggiatura a prescindere dal volume dei voti del pubblico. Per raggiungere tale scopo, è stata sviluppata un'ontologia in grado di formalizzare eventi chiave e situazioni ricorrenti della serie, al fine di dedurre in modo automatico una classificazione semantica degli episodi tramite l'uso di un motore di inferenza (*reasoner*).

Strumenti utilizzati

La base di conoscenza (*Knowledge Base*) è stata modellata e formalizzata sfruttando il linguaggio **OWL** (Web Ontology Language), in quanto standard basato sulle Logiche Descrittive (DL), attraverso l'utilizzo dell'editor grafico **Protégé**. L'interazione programmatica tra la base di conoscenza e l'ambiente di sviluppo in Python è stata resa possibile dalla libreria *owlready2*. Infine, per derivare nuova conoscenza implicita e validare logicamente il modello, il sistema si è affidato a **HermiT**, un potente *reasoner* semantico.

Decisioni di Progetto

Come suggerito dalla metodologia di progettazione dell'Ingegneria della Conoscenza, lo sviluppo del sistema si è diviso in due fasi ben distinte: la formulazione della TBox e il popolamento della ABox.

- **TBox (Terminological Box):** In Protégé è stata definita la tassonomia delle classi del dominio (ad esempio Episodio, Evento, Personaggio, PremioAziendale) e le relazioni che le collegano (come la *Object Property* *haEvento* o *haPersonaggio*). Successivamente, per istruire la macchina su come valutare il successo narrativo, sono state scritte le regole logiche di inferenza per le classi target *Episodio_eccellente* ed *Episodio_scarso*, sfruttando le condizioni necessarie e sufficienti (costrutto *Equivalent To*). Si è stabilito formalmente, ad esempio, che un episodio contenente un matrimonio o il premio aziendale "Dundie" rappresenti un piccolo qualitativo assoluto, mentre l'assenza del protagonista principale "Michael Scott" (evento caratterizzante le ultime stagioni) qualifichi l'episodio in una fascia di criticità.
- **ABox (Assertional Box):** Per limitare l'inserimento manuale e rendere l'applicativo scalabile, il popolamento degli individui è stato automatizzato via Python. Lo script si occupa di analizzare le *feature* testuali del dataset originario (come la colonna della trama "About", i titoli "EpisodeTitle" o i nomi delle "GuestStars"): laddove il testo presenti corrispondenze con gli eventi dell'ontologia, Python istanzia automaticamente l'episodio (es. *Episode_27*) e lo collega agli individui semantici corretti della Knowledge Base.

Valutazione

Una volta popolata interamente l'ontologia, il codice Python ha delegato il compito valutativo avviando il motore HermiT. Il *reasoner*, come previsto dalla logica formale, ha analizzato l'intera rete

di classi e applicato il ragionamento deduttivo agli individui della ABox per ri-classificarli in base agli assiomi dichiarati.



L'esecuzione del motore logico ha generato una diagnostica di enorme successo, suddividendo l'intero dominio della serie in modo semanticamente ineccepibile. HermiT ha dedotto la seguente distribuzione:

- **15 episodi "Eccellente":** isolando perfettamente i finali di stagione e gli archi narrativi fondamentali.
- **41 episodi "Scarso":** raggruppando esattamente gli episodi penalizzati da difetti di sceneggiatura formalizzati nelle TBox.
- **132 episodi "Buono":** gli episodi standard che non infrangono alcun vincolo né in positivo né in negativo.



Questi risultati confermano che la macchina, pur non conoscendo nulla dei voti di gradimento originari e dei dati numerici, ha "compreso" la sceneggiatura dell'opera comportandosi da vera intelligenza artificiale. L'etichetta semantica dedotta da HermiT è stata quindi incapsulata nella nuova variabile Semantic_Class, pronta per essere fusa con il dataset di partenza.

Sistema Ibrido (Integrazione tra Modelli)

Sommario

Il modulo finale concretizza il vero paradigma dell'Ingegneria della Conoscenza, unendo l'approccio puramente statistico (Capitolo 2) con quello semantico-deduttivo (Capitolo 3). L'obiettivo è verificare se l'algoritmo di apprendimento supervisionato, una volta arricchito con la classificazione logica degli episodi generata dal *reasoner*, riesca a ottenere predizioni più robuste, bilanciate e generalizzabili rispetto al modello di base.

Strumenti utilizzati

Per l'integrazione della nuova conoscenza di dominio si è fatto uso della libreria pandas al fine di effettuare il *merge* dei dati. La nuova variabile testuale generata da HermiT è stata transcodificata in formato numerico compatibile con i modelli tramite la funzione LabelEncoder di scikit-learn.


Decisioni di Progetto

Il dataset originario, precedentemente ripulito dai campi non strutturati, è stato unito al dizionario dei risultati esportato dal modulo Python owlready2. Si è così ingegnerizzata una nuova feature denominata *Semantic_Class*, associata a ogni singolo episodio e valorizzata discrezionalmente dal *reasoner* (Eccellente, Buono, Scarso). I modelli *Decision Tree* e *Random Forest* sono stati quindi addestrati nuovamente (mantenendo la Nested Cross-Validation e la GridSearch per il *tuning* dei parametri) su questo dataset "ibrido".

Valutazione

L'addestramento sui dati arricchiti ha evidenziato comportamenti molto istruttivi da parte dei due modelli testati:

- **Decision Tree:** L'accuratezza è rimasta ferma al **62.69%** (esattamente come nel modello base). Questo risultato non indica un fallimento, ma dimostra i limiti dell'algoritmo ad albero singolo: a causa della sua natura "avida", il modello ha continuato a tagliare i nodi privilegiando variabili continue ad alta varianza (come i Voti), relegando l'informazione semantica in secondo piano o ignorandola.
- **Random Forest:** Il modello *ensemble*, creando una moltitudine di alberi decisionali decorrelati, è riuscito invece a sfruttare appieno la conoscenza di dominio. L'accuratezza è balzata dal 67.00% del modello base al **69.15%**, con un incremento proporzionale dell'F1-Score (salito al 68.83%). Il *GridSearchCV* ha inoltre stabilito che per fondere al meglio queste informazioni eterogenee, la foresta necessitava di un numero maggiore di stimatori, passando da 50 a 150 alberi ottimali.



Analizzando la *Feature Importance* della Random Forest ibrida, si nota un dettaglio tecnicamente rilevante: sebbene l'accuratezza generale sia salita, la barra della variabile `Semantic_Class` si posiziona in basso rispetto a feature puramente quantitative come `Votes` e `Viewership`. Questo fenomeno, noto come *High Cardinality Bias*, è tipico degli alberi decisionali, i quali tendono a premiare matematicamente le variabili continue con infiniti tagli possibili (i voti) rispetto alle variabili categoriche con pochissimi valori discreti (la nostra classe semantica a 3 valori). Tuttavia, l'innalzamento reale delle performance metriche (+2.15%) prova che la `Semantic_Class` interviene efficacemente nei nodi terminali per risolvere gli *edge cases*, correggendo il tiro della sola statistica negli episodi in cui il pubblico era più diviso.

Conclusioni

Il presente progetto dimostra l'efficacia pratica dell'integrazione di basi di conoscenza ontologiche nei flussi di Machine Learning. Come evidenziato dai risultati dell'approccio ibrido, l'utilizzo esclusivo di dati statistici (numero di voti e di spettatori) risulta insufficiente per valutare la complessità di un'opera artistica. Dotando il sistema di un classificatore semantico in OWL, gli algoritmi acquisiscono un punto di vista "umano" sulla sceneggiatura, migliorando le proprie capacità di predizione e generalizzazione.

L'impossibilità di superare il tetto del 70% di accuratezza riflette un limite intrinseco della logica formale applicata all'arte: un'ontologia, per quanto rigorosa, fatica a codificare concetti astratti ed emotivi quali l'ironia o il "cringe", elementi fondanti del successo di *The Office*. Per gli sviluppi futuri, al fine di colmare questo divario, si suggerisce di affiancare alla TBox tecniche di *Sentiment Analysis* basate sull'elaborazione del linguaggio naturale (NLP) applicata ai copioni. Questo permetterebbe di

estrarre e quantificare l'impatto emotivo di ciascuna battuta, dotando gli algoritmi di un'ulteriore feature decisiva.

Riferimenti Bibliografici

Dispense del corso "Ingegneria della Conoscenza", AA 2025-2026.

Riferimento per i fondamenti teorici dell'Apprendimento Supervisionato e della Rappresentazione della Conoscenza. D. Poole, A. Mackworth. *Artificial Intelligence: Foundations of Computational Agents* (3rd Edition). Cambridge University Press, 2023.

Pandas: User Guide. Documentazione ufficiale per la manipolazione del dataset. https://pandas.pydata.org/docs/user_guide/index.html Scikit-learn Documentation: Machine Learning in Python.

Riferimento per i moduli DecisionTreeClassifier, RandomForestClassifier e GridSearchCV. <https://scikit-learn.org/stable/>

Matplotlib Documentation. Riferimento per la generazione di grafici (Learning Curve e Feature Importance). <https://matplotlib.org/stable/>

Protégé Ontology Editor. Strumento open-source per la costruzione e la formalizzazione dell'ontologia in OWL. <https://protege.stanford.edu/> Owlready2:

Programmazione ontology-oriented. Documentazione della libreria Python per manipolare classi OWL ed eseguire il reasoner HermiT. <https://owlready2.readthedocs.io/>